

EJERCICIO SERIES TEMPORALES

CLASE 1

Ejercicio 1

Dada la serie, vuelos regulares en España desde Enero de 1995, con datos mensuales.

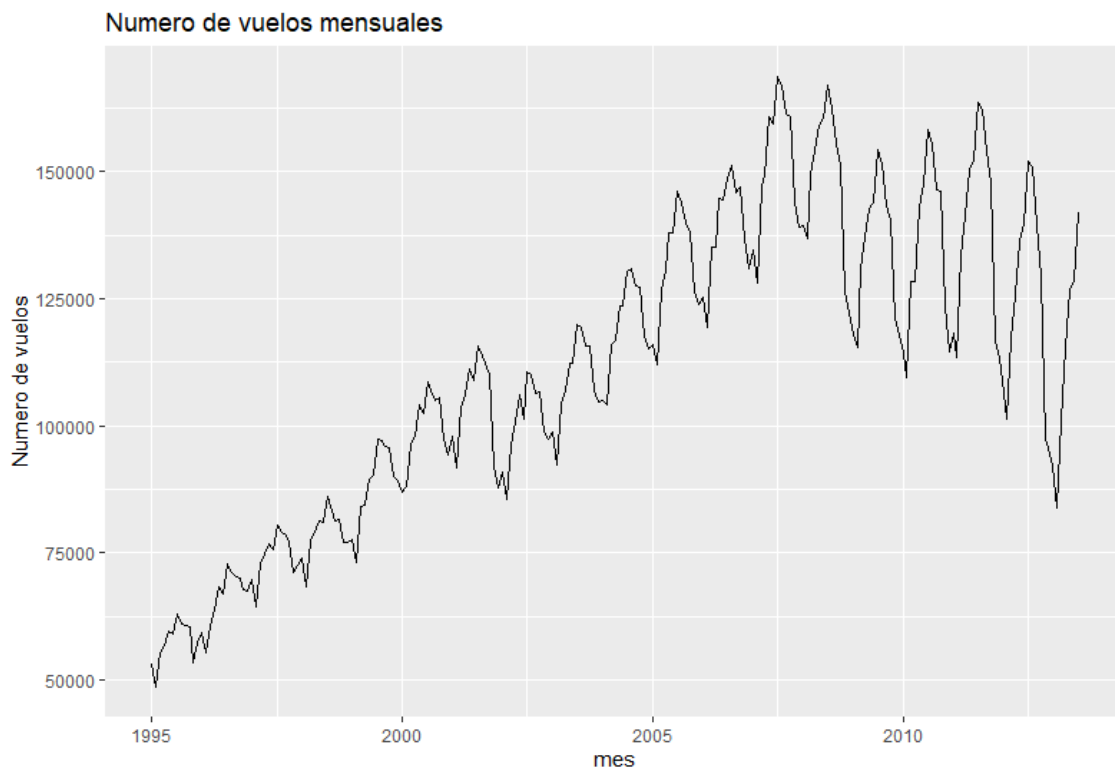
1. Representar la serie y comentar el gráfico. ¿La serie es estacionaria? ¿Tiene tendencia? ¿Tiene comportamiento estacional? ¿Cuál es el periodo?

#Numero de vuelos en España

```
vuelos <- ts(VUELOS[,-1], start=c(1995,1), frequency=12)
```

```
autoplot(vuelos)+ ggtitle("Numero de vuelos mensuales") +
```

```
xlab("mes") + ylab("Numero de vuelos")
```



¿La serie es estacionaria? No, porque no tiene media constante.

¿Tiene tendencia? Si, primero creciente y decreciente a partir de 2008

¿Tiene comportamiento estacional? Si ¿Cuál es el periodo? 12

- Calcular los coeficientes de estacionalidad. ¿Qué mes tiene un coeficiente mayor? ¿Qué significa? ¿Cuál es el mes que tiene menor? ¿Cuál es su significado?

#Guardamos los componentes de la descomposición estacional en

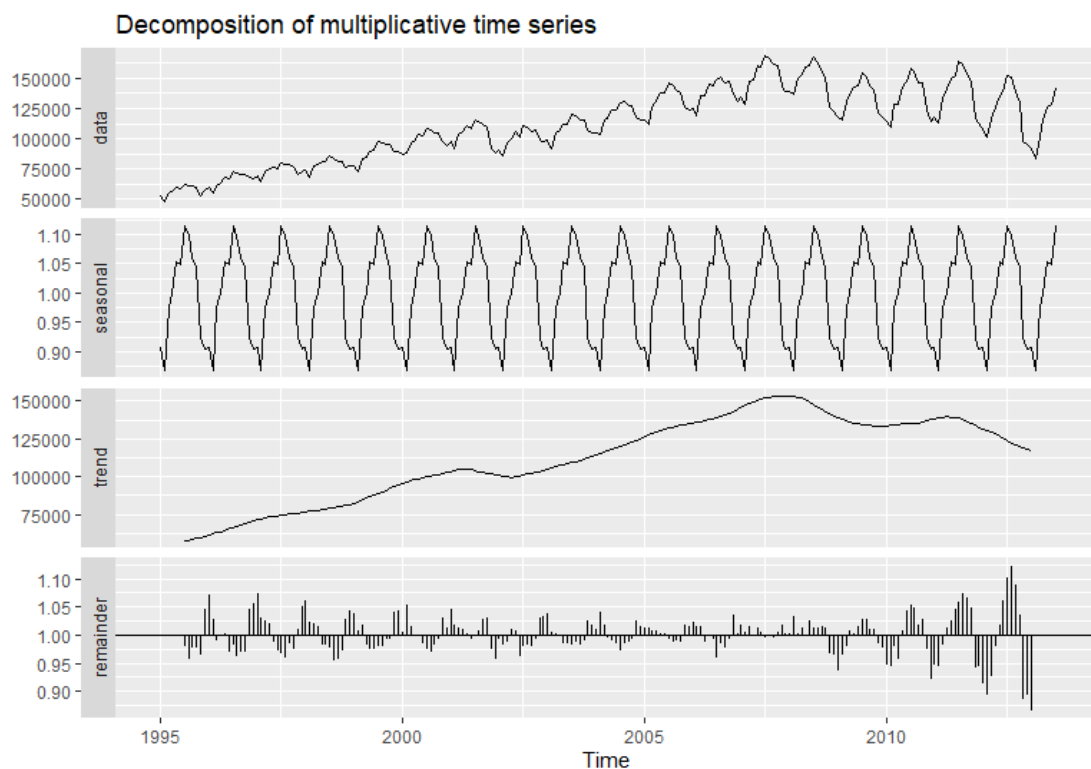
```
vuelos_Comp<- decompose(vuelos,type=c("multiplicative"))
```

```
print(vuelos_Comp)
```

| 1,00 | 2,00 | 3,00 | 4,00 | 5,00 | 6,00 | 7,00 | 8,00 | 9,00 | 10,00 | 11,00 | 12,00 |
|------|------|------|------|------|------|------|------|------|-------|-------|-------|
| 0,91 | 0,87 | 0,98 | 1,00 | 1,05 | 1,05 | 1,11 | 1,10 | 1,06 | 1,04 | 0,92 | 0,90 |


- Representar la serie, la componente estacional, la estimación de la tendencia y el error. ¿Qué dirías sobre la tendencia del número de vuelos en los últimos cuatro años? ¿Y sobre su comportamiento estacional?

```
autoplot(vuelos_Comp,ts.colour = "blue")
```




- Representar sobre la serie de vuelos original, la tendencia calculada con la descomposición y la serie ajustada estacionalmente. ¿Cómo se calcula la serie ajustada estacionalmente?

```
autoplot(vuelos, series="Datos") +  
  
  autolayer(trendcycle(vuelos_Comp), series="Tendencia") +  
  
  autolayer(seasadj(vuelos_Comp), series="Estacionalmente ajustada") +  
  
  xlab("Year") + ylab("Vuelos") +  
  
  ggtitle("Serie de vuelos") +  
  
  scale_colour_manual(values=c("gray", "blue", "red"),  
  
    breaks=c("Datos", "Estacionalmente ajustada", "Tendencia"))
```



5. Representar las series de cada año ¿En que año hubo más vuelos?

```
ggseasonplot(vuelos, year.labels=TRUE, year.labels.left=TRUE) +  
  
  ylab("Numero") + ggtitle("Seasonal plot: vuelos")
```



6. Para comprobar la eficacia de los métodos de predicción que vamos a hacer en los siguientes apartados sobre el fichero Vuelos_TR eliminando de Vuelos los últimos datos observados (un periodo en las series estacionales o aproximadamente 10 observaciones). Estos últimos valores se reservan para comparar con las predicciones realizadas por cada uno de los métodos. **Luego ajustamos los modelos sobre la serie sin esos últimos datos en los siguientes apartados**

reservamos el ultimo año para comparar las predicciones

```
vue_train <- window(vuelos, end=c(2012,7))
```

#Vamos a predecir los valores que hemos reservado para test

```
h <- length(vuelos) - length(vue_train)
```

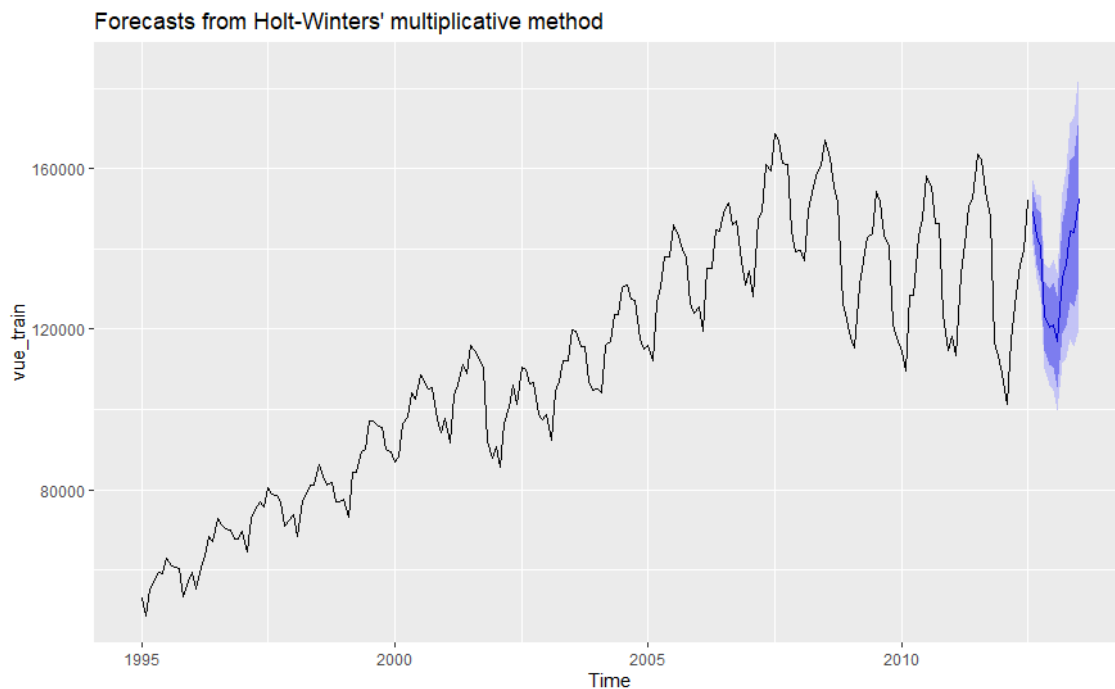
```
print(h)
```

```
[1] 12
```

7. Encontrar el modelo de suavizado exponencial más adecuado. Para dicho modelo, representar gráficamente la serie observada y la suavizada con las predicciones para un periodo que se considere adecuado.

```
vuelos_sh <- hw(vue_train,seasonal="multiplicative", h)
print(vuelos_sh)
autoplot(vuelos_sh)
```

| Po | int | Forecast | Lo 80 | Hi 80 | Lo 95 | Hi 95 |
|-----|------|----------|----------|----------|-----------|----------|
| Aug | 2012 | 149089 | 143807,9 | 154370 | 141012,34 | 157165,6 |
| Sep | 2012 | 143101,7 | 136175,2 | 150028,2 | 132508,58 | 153694,9 |
| Oct | 2012 | 140710,7 | 132356,8 | 149064,7 | 127934,48 | 153487 |
| Nov | 2012 | 123350,5 | 114800,6 | 131900,4 | 110274,58 | 136426,5 |
| Dec | 2012 | 120509 | 111031,1 | 129986,9 | 106013,73 | 135004,2 |
| Jan | 2013 | 121119,4 | 110510,1 | 131728,6 | 104893,96 | 137344,8 |
| Feb | 2013 | 116771,7 | 105529,5 | 128013,9 | 99578,25 | 133965,1 |
| Mar | 2013 | 132834,3 | 118916,1 | 146752,5 | 111548,3 | 154120,4 |
| Apr | 2013 | 136214,2 | 120800 | 151628,5 | 112640,18 | 159788,3 |
| May | 2013 | 144462,8 | 126915,6 | 162010,1 | 117626,63 | 171299,1 |
| Jun | 2013 | 144155,2 | 125455,4 | 162855,1 | 115556,24 | 172754,2 |
| Jul | 2013 | 152368,1 | 131349 | 173387,2 | 120222,18 | 184514 |



Ejercicio 2.

El fichero PARO_S contiene los datos de Tasas de paro por sexo para cada trimestre desde 2002.

Crear la variable fecha.

1. Representar las dos series juntas. ¿Qué podemos decir sobre el comportamiento del paro en mujeres y hombres?

#Serie paro según sexo


```
ParoS_ts<- ts(Paro_S[,-1], start=c(2002,1), frequency=4)
```

```
ParoH<- ts(Paro_S[,2], start=c(2002,1), frequency=4)
```

```
ParoM<- ts(Paro_S[,3], start=c(2002,1), frequency=4)
```

#Juntas

```
autoplot(ParoS_ts)
```



2. Para la **serie tasa de paro en hombres** realizar el suavizado de la serie **utilizando el modelo adecuado**. Hacer los siguientes apartados sobre el fichero ParoH_R eliminando los datos del último año observado. Estos últimos valores se reservan para comparar con las predicciones realizadas por cada uno de los métodos. Realizar predicciones para el año siguiente al último observado

#Seleccionamos los valores de paro quitando los últimos 4

```
ParoH_R<-window(ParoH,end=c(2018,2))
```

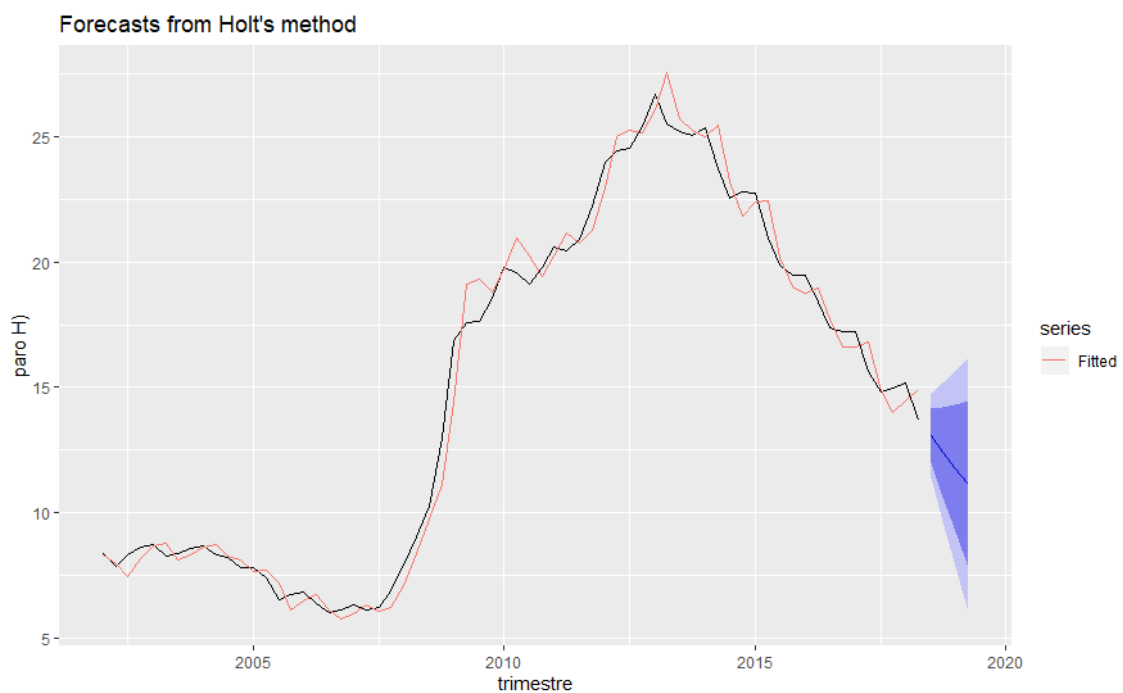
a. Representar la serie original y la suavizada con las predicciones.

```
ParoH_sh <- holt(ParoH_R, h=4)
```

```
autoplot(ParoH_sh) +
```

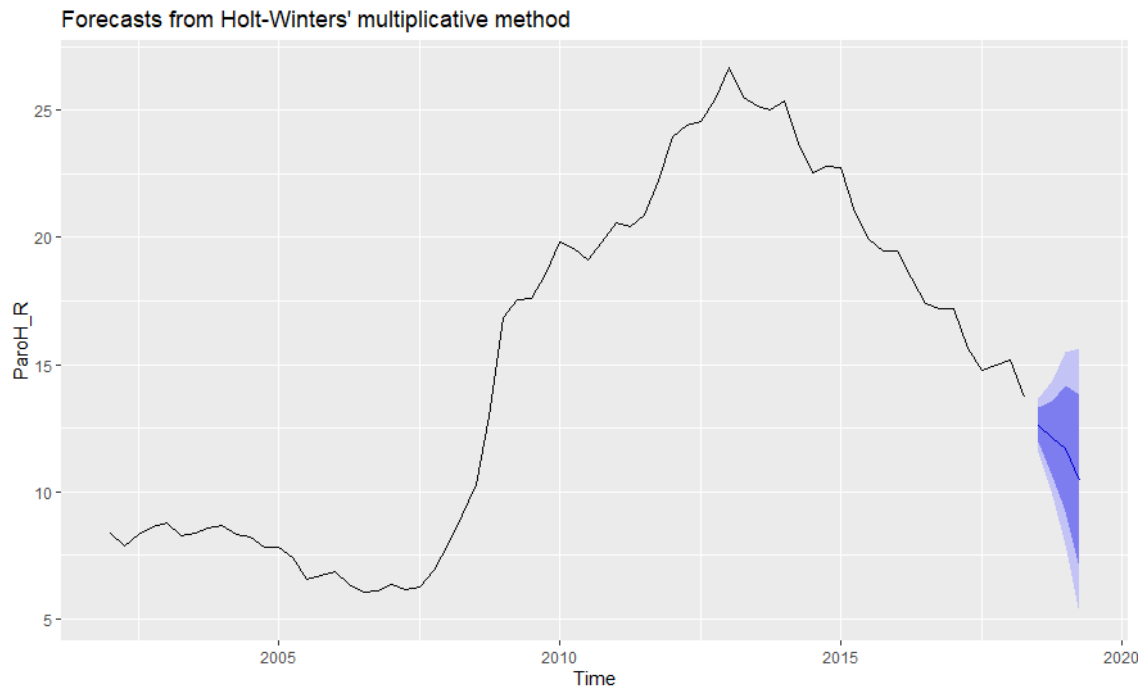
```
  autolayer(fitted(ParoH_sh), series="Fitted") +
```

```
  ylab("paro H") + xlab("trimestre")
```



```
ParoH_shw <- hw(ParoH_R, h=4, seasonal="multiplicative",level = c(80, 95))
```

```
autoplot(ParoH_shw)
```



- b. Sobre la tabla de las predicciones ¿Qué observas en el comportamiento de los intervalos de confianza para la predicción? ¿A que es debido dicho comportamiento?

```
print(ParoH_shw)
```

| Point | Forecast | Lo 80 | Hi 80 | Lo 95 | Hi 95 |
|---------|----------|-----------|----------|-----------|----------|
| 2018 Q3 | 12,63234 | 11,94119 | 13,32349 | 11,575317 | 13,68936 |
| 2018 Q4 | 12,09345 | 10,611763 | 13,57513 | 9,827406 | 14,35949 |
| 2019 Q1 | 11,69801 | 9,212879 | 14,18314 | 7,897331 | 15,49868 |
| 2019 Q2 | 10,43216 | 7,020066 | 13,84426 | 5,213812 | 15,65051 |

- c. Sobre la tabla de estadísticos del modelo ¿Cuánto vale la estimación de los parámetros de suavizado? Escribir las ecuaciones del modelo con los valores de los coeficientes estimados.

```
ParoH_shw[["model"]]
```

Smoothing parameters:

alpha = 0.9925

beta = 0.8817

gamma = 0.0075

$$L_t = 0.9925(x_t - S_{t-s}) + (1 - 0.9925)(L_{t-1} + b_{t-1})$$

$$b_t = 0.8817(L_t - L_{t-1}) + (1 - 0.8817)b_{t-1}$$

$$S_t = 0.0075(x_t - L_t) + (1 - 0.0075)S_{t-s}$$

$$\hat{x}_{n+m} = L_n + b_n m \quad m \geq 1$$

Initial states:

l = 8.5206

b = -1.1178

s = 0.9961 0.9745 0.9951 1.0343

sigma: 0.0427

| AIC | AICC | BIC |
|----------|----------|----------|
| 211.6900 | 214.9043 | 231.3969 |